

Fase 2. Exploració i preparació de les dades

1. Introducció al dataset

Les dades inicials consten de dos datasets, un dels quals és producte de l'altre:

1. 100_Batches_IndPenSim_V3.csv: dades crues
2. 100_Batches_IndPenSim_Statistics.csv: estadístiques per lots del dataset anterior

És per això que, tot i tenir els dos fitxers, en tot moment ens referim al primer dataset.

1.1. Descripció del dataset

El dataset IndPenSim és un conjunt de dades generat mitjançant una simulació matemàtica avançada d'un sistema de fermentació de penicil·lina de 100.000 litres. Aquest dataset representa el més gran conjunt de dades disponible per a anàlisi avançada de dades en la indústria biofarmacèutica.

Nombre de batches	100 lots de fermentació
Mida del dataset	~2.7 GB de dades temporals
Tipus de mesures	Variables de procés + Espectroscòpia Raman
Resolució temporal	Mesures cada 0.5 - 1.0 hores
Durada dels batches	Variable: 200-400 hores
Estratègies de control	4 tipus diferents (Recipe, Operators, APC, Faults)
Variables disponibles	~50 variables de procés + espectre Raman

1.2. Estructura dels lots per estratègia de control

Els 100 batches estan dividits en 4 grups segons l'estratègia de control utilitzada:

Batches	Estratègia	Característiques	Objectiu
1-30	Recipe-Driven	Control basat en recepta definida	Reproducibilitat
31-60	Operator Control	Control manual per operaris	Flexibilitat
61-90	APC amb Raman	Control amb espectroscòpia	Optimització
91-100	Batches amb Falles	Desviacions i errors del procés	Detecció anomalies

1.3. Variables mesurades

El dataset conté aproximadament 50 variables de procés mesures en temps real, que es poden classificar en diferents categories:

Categoria	Variables principals	Nº
Variables d'estat	Biomassa, Penicil·lina, Substrat, Volumen	4-6
Variables operacionals	Temperatura, pH, DO, Agitació, Aeració	5-8
Variables de flux	Cabals d'alimentació (substrat, base, àcid)	3-5
Variables metabòliques	OUR, CER, RQ (Quocient respiratori)	3-4
Espectroscòpia Raman	Intensitats espectrals (múltiples longituds d'onda)	20-30
Variables calculades	k _L ·a, viscositat, rendiments	3-5

2. Anàlisi exploratòria de dades (EDA)

2.1. Metodologia d'anàlisi

L'anàlisi exploratòria seguirà una estratègia sistemàtica per comprendre les característiques del dataset i identificar patrons rellevants:

1. Càrrega i verificació de la integritat de les dades
2. Anàlisi de valors perduts i tractament d'outliers
3. Visualització de l'evolució temporal de variables clau
4. Comparació entre estratègies de control
5. Anàlisi de correlacions entre variables
6. Identificació de batches anòmals
7. Selecció de característiques rellevants

Per a fer tot això, s'ha utilitzat els següents scripts (disponibles annexes):

01_exploratory_data_analysis.py

02_temporal_visualization.py

03_data_cleaning_and_feature_engineering.py

04_correlation_and_feature_selection.py

2.2. Càrrega de dades

Per a la càrrega de dades s'ha realitzat des de kaggle a partir del codi proporcionat per [Kaggle](#):

```
import kagglehub
path = kagglehub.dataset_download("stephengoldie/big-databiopharmaceutical-manufacturing")
print("Path to dataset files:", path)
```

L'origen de les dades, com ja s'ha mencionat és de IndPenSim, concretament de *Industrial-Scale Penicillin Simulation (V2)* (<http://www.industrialpenicillinsimulation.com/>) però hi he accedit a través de Stephen Goldrick que les ha penjat a Kaggle (<https://www.kaggle.com/datasets/stephengoldie/big-databiopharmaceutical-manufacturing/d/ata>).

2.3. Inspecció inicial de les dades

Degut al gran tamany de les dades, no podia inspeccionar inicialment el dataset, sinó que ho he hagut de fer a través d'un script auxiliar (visualitzar_dades.py):

```
1  import pandas as pd
2  from datetime import datetime
3
4  NOM_FITXER = "100_Batches_IndPenSim_V3.csv"
5  NOM_SORTIDA = "analisi_dataset.txt"
6
7  print(f"📁 Processant {NOM_FITXER}...")
8
9  try:
10     if NOM_FITXER.endswith('.csv'):
11         df = pd.read_csv(NOM_FITXER)
12     elif NOM_FITXER.endswith(('.xls', '.xlsx')):
13         df = pd.read_excel(NOM_FITXER)
14     else:
15         df = pd.read_csv(NOM_FITXER, sep=None, engine='python')
16
17     with open(NOM_SORTIDA, 'w', encoding='utf-8') as f:
18
19         f.write("=" * 80 + "\n")
20         f.write(f"ANÀLISI DE DATASET\n")
21         f.write(f"Generat: {datetime.now().strftime('%Y-%m-%d %H:%M:%S')}\n")
22         f.write(f"Fitxer original: {NOM_FITXER}\n")
23         f.write("=" * 80 + "\n\n")
24
25         # =====
26         # 📌 INFORMACIÓ GENERAL
27         # =====
28         f.write("📌 INFORMACIÓ GENERAL:\n")
29         f.write("-" * 40 + "\n")
30         f.write(f"▶ Total files: {df.shape[0]}\n")
31         f.write(f"▶ Total columnes: {df.shape[1]}\n")
32         f.write(f"▶ Memòria utilitzada: {df.memory_usage(deep=True).sum() / 1024**2:.2f} MB\n\n")
33
```

```

34 # =====
35 # 2 LLISTAT COMPLET DE COLUMNES
36 # =====
37 f.write("📄 LLISTAT COMPLET DE COLUMNES:\n")
38 f.write("-" * 40 + "\n")
39 for i, col in enumerate(df.columns, 1):
40     f.write(f"{i:3}. {col}\n")
41 f.write(f"\n▶ TOTAL COLUMNES: {len(df.columns)}\n\n")
42
43 # =====
44 # 3 PRIMERES 5 FILES
45 # =====
46 f.write("📄 PRIMERES 5 FILES:\n")
47 f.write("-" * 40 + "\n")
48
49 # Convertir les primeres 5 files a string
50 head_str = df.head().to_string()
51 f.write(head_str + "\n\n")
52
53 # =====
54 # 4 TIPUS DE DADES
55 # =====
56 f.write("📄 TIPUS DE DADES (primeres 10 columnes):\n")
57 f.write("-" * 40 + "\n")
58 for col in df.columns[:10]:
59     f.write(f"    {col}: {df[col].dtype}\n")
60
61 # Si hi ha més de 10 columnes, indicar-ho
62 if len(df.columns) > 10:
63     f.write(f"    ... i {len(df.columns) - 10} columnes més\n")
64
65 # =====
66 # 5 ESTADÍSTIQUES BÀSIQUES (opcional)
67 # =====
68 f.write("\n📄 ESTADÍSTIQUES BÀSIQUES (columnes numèriques):\n")
69 f.write("-" * 40 + "\n")
70

```

```

71 # Seleccionar columnes numèriques
72 num_cols = df.select_dtypes(include=['number']).columns[:5] # Primeres 5 numèriques
73
74 if len(num_cols) > 0:
75     for col in num_cols:
76         f.write(f"\n{col}:\n")
77         f.write(f"    Min: {df[col].min():.2f}\n")
78         f.write(f"    Max: {df[col].max():.2f}\n")
79         f.write(f"    Mitjana: {df[col].mean():.2f}\n")
80         f.write(f"    Mediana: {df[col].median():.2f}\n")
81 else:
82     f.write("    No hi ha columnes numèriques\n")
83
84 # PEU DE PÀGINA
85 f.write("\n" + "=" * 80 + "\n")
86 f.write("✅ ANÀLISI COMPLETADA\n")
87 f.write("=" * 80 + "\n")
88
89 print(f"✅ Fitxer '{NOM_SORTIDA}' generat correctament!")
90 print(f"📁 Pots obrir-lo amb qualsevol editor de text")
91
92 except FileNotFoundError:
93     print(f"\n❌ ERROR: No es troba el fitxer '{NOM_FITXER}'")
94     print("🔍 Comprova que:")
95     print("    - El fitxer està a la mateixa carpeta que aquest script")
96     print("    - El nom està escrit correctament (majúscules/minúscules)")
97     print("    - L'extensió del fitxer és correcta")
98 except Exception as e:
99     print(f"\n❌ ERROR INESPERAT: {e}")

```

Obtenint els següents resultats, entre d'altres consultables al fitxer analisi_dataset.txt (veure https://github.com/aina-carbonell/besso_digital_optimitzacio_produccio_penicilina juntament amb la resta de fitxers mencionats en qualsevol moment):

1. Time (h)
2. Aeration rate(F_g :L/h)
3. Agitator RPM(RPM:RPM)
4. Sugar feed rate(F_s :L/h)
5. Acid flow rate(F_a :L/h)
6. Base flow rate(F_b :L/h)
7. Heating/cooling water flow rate(F_c :L/h)
8. Heating water flow rate(F_h :L/h)
9. Water for injection/dilution(F_w :L/h)
10. Air head pressure(pressure:bar)
11. Dumped broth flow($F_{removed}$:L/h)
12. Substrate concentration(S :g/L)
13. Dissolved oxygen concentration(DO_2 :mg/L)
14. Penicillin concentration(P :g/L)
15. Vessel Volume(V :L)
16. Vessel Weight(W_t :Kg)
17. pH(pH:pH)
18. Temperature(T :K)
19. Generated heat(Q :kJ)
20. carbon dioxide percent in off-gas(CO_2 outgas:%)
21. PAA flow(F_{paa} :PAA flow (L/h))
22. PAA concentration offline(PAA_offline:PAA ($g\ L^{-1}$)))
23. Oil flow(F_{oil} :L/hr)
24. NH_3 concentration off-line(NH_3 _offline: NH_3 ($g\ L^{-1}$)))
25. Oxygen Uptake Rate(OUR:($g\ min^{-1}$)))
26. Oxygen in percent in off-gas(O_2 : O_2 (%))

27. Offline Penicillin concentration($P_{\text{offline}}: P(\text{g L}^{-1})$)
28. Offline Biomass concentratio($X_{\text{offline}}: X(\text{g L}^{-1})$)
29. Carbon evolution rate(CER:g/h)
30. Ammonia shots($\text{NH}_3_{\text{shots}}:\text{kgs}$)
31. Viscosity($\text{Viscosity}_{\text{offline}}:\text{centPoise}$)
32. Fault reference($\text{Fault}_{\text{ref}}:\text{Fault ref}$)
33. 0 - Recipe driven 1 - Operator controlled($\text{Control}_{\text{ref}}:\text{Control ref}$)
34. 1- No Raman spec
35. 1-Raman spec recorded
36. 2-PAT control($\text{PAT}_{\text{ref}}:\text{PAT ref}$)
37. Batch reference($\text{Batch}_{\text{ref}}:\text{Batch ref}$)
38. Batch ID
39. Fault flag
- 40-2239. numeració del 2400 al 201

I obtenint que l'estadística de les primeres files eren les mateixes que les proporcionades al dataset _Statistics.csv, de manera que es dona per verificat aquell dataset.

A més a més, un cop vista l'estructura del dataset, s'ha pogut procedir a la creació dels scripts mencionats, obtenint el següent resum (01_dataset_summary.txt):

RESUM DE L'ANÀLISI EXPLORATÒRIA

Dataset IndPenSim - Producció de Penicil·lina

 Dimensions del dataset: 113,935 files × 2,239 columnes

 Memòria utilitzada: 1946.26 MB

 Variables de procés: 39

 Columnes d'espectroscòpia Raman: 2200

 Nombre total de batches: 100

 Mostres per batch (mitjana): 1139

 Durada mitjana per batch: 227.7 hores

 Variables clau identificades:

- Temps: Time (h)

- Substrat: Substrate concentration(S:g/L)
- Oxigen Dissolt: Dissolved oxygen concentration(DO2:mg/L)
- Penicil·lina: Penicillin concentration(P:g/L)
- Volumen: Vessel Volume(V:L)
- pH: pH(pH:pH)
- Temperatura: Temperature(T:K)
- Agitació: Agitator RPM(RPM:RPM)
- Aeració: Aeration rate(Fg:L/h)
- OUR: Oxygen Uptake Rate(OUR:(g min⁻¹)))
- CER: Carbon evolution rate(CER:g/h)

2.4. Variables clau del procés


Basant-nos en la teoria del procés i estudis previs, les 9 variables més rellevants esperem que siguin:

Variable	Justificació
Biomass	Directament relacionada amb producció ($q_P \cdot X$)
Specific_production_rate	Velocitat específica de biosíntesi
time	Fase del procés (producció en fase estacionària)
Substrate	Control de limitació per substrat
DO	Metabolisme aeròbic essencial
pH	Afecta activitat enzimàtica de biosíntesi
OUR / CER	Indicadors d'activitat metabòlica
Temperature	Afecta cinètica enzimàtica
Volume	Estratègia fed-batch i dilució


Obtenint que realment les variables que més influeixen en el procés són:

1. cumulative_penicillin (r = +0.995)
2. substrate (r = -0.078)
3. RQ (r = +0.078)
4. specific_production_rate (r = -0.138)
5. substrate_rate (r = +0.081)

- 6. base_flow (r = -0.122)
- 7. DO (r = -0.330)
- 8. OUR (r = +0.257)
- 9. viscosity (r = +0.787)




Matriu Correlacio - Top 9 + Penicil.lina




3. Visualització temporal de variables clau

3.1. Perfils temporals d'un lot individual


Perfil Temporal - Batch 15




Perfil Temporal - Batch 75



Perfil Temporal - Batch 95



3.2. Comparació entre estratègies de control



4. Identificació de lots amb errors

4.1. Anàlisi dels lots

Els batches 91-100 contenen errors que representen desviacions del procés. L'objectiu és identificar aquestes anomalies i comprendre el seu impacte utilitzant Principi Component Analysis (PCA).

5. Tractament i neteja de dades

5.1. Detecció de valors perduts i estratègies d'imputació


Els valors NaN s'han imputat segons la naturalesa de cada variable:


- Variables continues: interpolació
- 'Agitation', 'Airflow', 'Substrate_Feed': forward fill (últim valor llegit)
- Variables amb poca variabilitat: mitjana
- Variables amb outliers i altres casos: mediana

5.2. Detecció i tractament d'outliers

S'ha generat el fitxer csv que conté el percentatge de valor atípics de cada una de les variables i els següents boxplots per a visualitzar-ho correctament, tenint que les variables amb més outliers són:

- RQ
- temperature
- acid_flow
- pH
- substrate_rate
- OUR
- substrate





6. Enginyeria de característiques

6.1. Generació del dataset final

A més a més, s'ha creat un dataset final amb les 33 columnes més rellevants per a l'anàlisi i modelatge. Aquestes inclouen variables originals, derivades i característiques calculades:

Nom de la Columna	Descripció / Càlcul
time	Temps de fermentació (h)
Biomass	Concentració de biomassa (g/L)
Penicillin	Concentració de penicil·lina (g/L) [TARGET]
Substrate	Concentració de substrat - glucosa (g/L)
DO	Oxigen dissolt (% saturació)
Temperature	Temperatura del reactor (°C)
pH	pH del medi
Agitation	Velocitat d'agitació (rpm)
Airflow	Cabal d'aire (L/min o VVM)
Volume	Volumen del reactor (L)
Substrate_Feed	Cabal d'alimentació de substrat (L/h)
Acid_Flow	Cabal d'àcid per control de pH (L/h)
Base_Flow	Cabal de base per control de pH (L/h)
OUR	Oxygen Uptake Rate (mmol/L/h)
CER	CO ₂ Evolution Rate (mmol/L/h)
RQ	Quocient respiratori: $RQ = CER / OUR$
kLa	Coeficient de transferència d'O ₂ (h ⁻¹)
Viscosity	Viscositat aparent del medi (cP)
Biomass_rate	dX/dt - Taxa de creixement (g/L/h)
Penicillin_rate	dP/dt - Taxa de producció (g/L/h)
Substrate_rate	dS/dt - Taxa de consum (g/L/h)
Specific_growth_rate	$\mu = (1/X) \cdot (dX/dt)$ (h ⁻¹)
Specific_production_rate	$q_P = (1/X) \cdot (dP/dt)$ (g_P/g_X/h)

Nom de la Columna	Descripció / Càlcul
Yield_PX	Rendiment P/X acumulat (g_P/g_X)
Yield_PS	Rendiment P/S acumulat (g_P/g_S)
Cumulative_Substrate	Substrat total consumit (g)
Cumulative_Penicillin	Penicil·lina total produïda (g)
Power_input	Potència d'agitació (kW)
Heat_generation	Generació de calor metabòlic (kW)
Raman_PC1	Component principal 1 de Raman
Raman_PC2	Component principal 2 de Raman
Raman_PC3	Component principal 3 de Raman
Batch_ID	Identificador del batch (1-100)

7. Conclusions i recomanacions

7.1. Principals conclusions de l'anàlisi exploratòria

1. El dataset IndPenSim proporciona dades exhaustives de 100 batches amb diferents estratègies de control, permetent una anàlisi comparativa robusta.
2. Els batches controlats amb APC (Advanced Process Control) utilitzant espectroscòpia Raman mostren rendiments més consistents i elevats comparats amb les estratègies recipe-driven i control manual.
3. Els batches 91-100 amb falles intencionades presenten desviacions significatives en múltiples variables, especialment en DO, pH i rendiment final, proporcionant dades valuoses per a detecció d'anomalies.
4. L'anàlisi de correlació identifica la biomassa, les taxes específiques de producció, i les variables metabòliques (OUR, CER) com els predictors més forts de la concentració de penicil·lina.
5. La generació del dataset de 33 columnes incorpora variables derivades essencials (taxes de canvi, velocitats específiques, rendiments) que capturen millor la dinàmica del procés que les variables originals soles.
6. La selecció de les 9 variables més rellevants redueix la dimensionalitat mantenint el poder predictiu, essencial per a models de machine learning eficients.

7.2. Recomanacions per al modelatge (fase 3)

1. Utilitzar tècniques de normalització/escalat (StandardScaler, MinMaxScaler) abans d'entrenar models per garantir que totes les variables contribueixen equitativament.
2. Implementar validació creuada estratificada per estratègia de control per assegurar que el model generalitza bé a totes les condicions operacionals.
3. Considerar models basats en sèries temporals (LSTM, GRU) que poden capturar la dependència temporal inherent al procés de fermentació.
4. Desenvolupar models separats per a cada fase del procés (creixement, transició, producció) ja que la cinètica i les relacions entre variables canvien significativament.
5. Utilitzar tècniques d'ensemble (Random Forest, Gradient Boosting, Stacking) per combinar múltiples models i millorar la robustesa de les prediccions.
6. Implementar explicabilitat dels models (SHAP, LIME) per comprendre quines variables són més importants en diferents condicions i fases del procés.
7. Validar els models amb els batches amb falles (91-100) per avaluar la capacitat de detecció d'anomalies i robustesa davant de pertorbacions.